

Detección Hiperlocal de Organizaciones Criminales en la CDMX: Un Pipeline de Datos mediante OCR, Modelos de Lenguaje y Análisis Espacial

1st Peralta Lezama Isaac
Licenciatura en Ciencia de Datos
Instituto Politécnico Nacional (ESCOM)
Ciudad de México, México
isaac.peralta220102@gmail.com

Resumen—Este artículo presenta una metodología computacional avanzada para la creación de una base de datos georeferenciada sobre violencia criminal en la Ciudad de México. Inspirado en metodologías previas de detección macroespacial, este trabajo transiciona a una resolución microespacial, implementando un pipeline de ingeniería de datos que transforma reportes gubernamentales no estructurados en matrices de datos con resolución a nivel de Área Geoestadística Básica (AGEB). El sistema integra Web Scraping incremental, digitalización óptica (OCR) y extracción de entidades (NER) utilizando modelos de lenguaje locales. Los resultados comprenden un dataset purificado desplegado en un dashboard interactivo que permite la visualización de hotspots delictivos y el análisis de densidad espacial, validando la eficacia de la Ciencia de Datos para el estudio de la seguridad ciudadana.

Index Terms—Ciencia de Datos, Procesamiento de Lenguaje Natural, RAG, Análisis Espacial, Web Scraping, CDMX.

I. INTRODUCCIÓN

La comprensión de las dinámicas delictivas en entornos metropolitanos de alta complejidad requiere de información oportuna, granular y estructurada. En la Ciudad de México (CDMX), si bien existen esfuerzos gubernamentales para el reporte de incidentes, la información frecuentemente se encuentra atrapada en formatos no estructurados, como boletines de prensa o reportes en PDF, lo que dificulta su análisis sistemático.

Tomando como referente metodológico el estudio de Osorio y Beltrán (2020) sobre la detección de organizaciones criminales mediante aprendizaje automático en México [1], el presente trabajo escala y refina dicha arquitectura para su aplicación específica en la capital del país. El objetivo principal de esta investigación consistió en transicionar de un análisis macroespacial a uno microespacial (a nivel colonia y AGEB), construyendo una base de datos inédita sobre la violencia urbana.

Para lograr esto, se propone una arquitectura integral que abarca desde la extracción automatizada de miles de documentos (Scraping), su digitalización mediante Reconocimiento Óptico de Caracteres (OCR), hasta el uso de Generación Aumentada por Recuperación (RAG) para la inferencia espacial de datos faltantes.

Este documento detalla la infraestructura técnica desarrollada y presenta los resultados obtenidos mediante su despliegue interactivo, demostrando cómo las herramientas modernas de Ciencia de Datos pueden transformar texto plano en inteligencia geoespacial accionable. El código fuente y las herramientas desarrolladas están disponibles de forma abierta para su revisión académica.

II. METODOLOGÍA

La arquitectura del sistema se diseñó bajo un enfoque de microservicios lógicos, divididos en tres etapas críticas: extracción incremental, digitalización por bloques y enriquecimiento semántico. A diferencia del modelo original de Osorio y Beltrán, que operaba sobre fuentes de noticias nacionales, este sistema se especializa en la infraestructura de boletines oficiales de la CDMX.

II-A. Fase 1: Extracción Web y Normalización

La fuente primaria de información es el portal de Síntesis Informativa de la Jefatura de Gobierno. Se desarrolló un crawler robusto utilizando Selenium WebDriver para navegar por el DOM dinámico del sitio. El sistema maneja una lógica incremental: consulta el repositorio local de enlaces y solo descarga aquellos archivos PDF que no han sido procesados previamente.

Un desafío técnico identificado fue la inconsistencia en los metadatos de los títulos oficiales (e.g., errores ortográficos como "didiembre." "septipembre"). Para resolver esto, se implementó un módulo de normalización basado en expresiones regulares (Regex) que traduce estas cadenas a un formato cronológico estándar YYYY_MM_DD.pdf, garantizando la integridad referencial del corpus.

```
1 # Fragmento extraído de scrapeo.ipynb
2 driver.get(url)
3 wait = WebDriverWait(driver, 20)
4 dropdown = wait.until(EC.element_to_be_clickable((By
5     .ID, "filter_year")))
6 Select(dropdown).select_by_visible_text(str(year))
7 # Filtrado de links ya existentes
8 nuevos_links = [l for l in recolectados if l not in
9     historial]
```

Listing 1. Lógica de navegación y filtrado incremental

II-B. Fase 2: Digitalización y OCR

Dado que los boletines son documentos PDF compuestos principalmente por imágenes escaneadas, se utilizó la suite *Poppler* para la rasterización y *Tesseract OCR* para la extracción de texto plano. El proceso se ejecuta de forma asíncrona para optimizar los tiempos de cómputo.

II-C. Fase 3: Extracción de Entidades con LLM Local

La innovación central de este pipeline radica en la sustitución de clasificadores estadísticos tradicionales por un modelo de lenguaje de gran escala (LLM): Llama 3.2, ejecutado localmente mediante el framework *Ollama*. Se diseñó un prompt estructurado (Chain-of-Thought) que obliga al modelo a devolver un objeto JSON con las siguientes entidades:

- **Delito:** Categorización según el código penal local.
- **Actores:** Identificación de grupos o individuos.
- **Ubicación:** Extracción de calles, colonias y alcaldías.




Figura 1. Arquitectura del Pipeline: Desde el scraping hasta la persistencia en CSV.

III. ANÁLISIS ESPACIAL Y GEORREFERENCIACIÓN

Una vez estructurados los datos, el sistema enfrenta el reto de la ambigüedad geográfica. Para ello, se implementó un motor de geocodificación que prioriza la jerarquía espacial (Calle → Colonia → Alcaldía).

En casos donde el reporte omite coordenadas precisas, se utiliza un módulo de "Agentic RAG" que consulta una base de conocimientos interna de polígonos de la CDMX para inferir el centroide de la colonia mencionada, logrando así recuperar eventos que de otro modo serían descartados en un análisis cartográfico tradicional.

IV. RESULTADOS Y EVALUACIÓN

El despliegue del pipeline permitió la consolidación de una base de datos histórica robusta. A continuación se presentan los hallazgos clave derivados del procesamiento de los reportes oficiales.

IV-A. Desempeño de la Geocodificación

De un total de 8,678 eventos delictivos identificados en el corpus original, el sistema logró una geolocalización exitosa en 6,269 casos, lo que representa una tasa de retención cartográfica del 72.24 %. Los eventos no geolocalizados correspondieron principalmente a reportes con descripciones de ubicación ambiguas o fuera del área de cobertura de la CDMX.

IV-B. Visualización Interactiva (Dashboard)

Para facilitar la interpretación de los datos, se desarrollaron dos herramientas de visualización utilizando la librería *Streamlit* y *Plotly Express*, disponibles para consulta pública:

- **Dashboard General:** Filtrado dinámico por delito y año (Enlace).
- **Análisis por AGEB:** Densidad espacial y coropletas (Enlace).

```
1 # Fragmento de mapa_ageb.py
2 # Cargar puntos y poligonos
3 gdf_eventos = gpd.GeoDataFrame(df, geometry=gpd.
4     points_from_xy(df.longitud, df.latitud), crs="
5     EPSG:4326")
6 agebs = gpd.read_file('09a.shp').to_crs(epsg=4326)
7 # Operación matemática de inclusión
8 eventos_en_ageb = gpd.sjoin(gdf_eventos, agebs, how=
9     "inner", predicate="within")
10 # Generación del mapa de coropletas
11 fig = px.choropleth_mapbox(agebs_con_datos, geojson=
12     agebs_con_datos.geometry,
13     locations=agebs_con_datos
14     .index, color='total_delitos',
15     mapbox_style="carto-
16     darkmatter")
```

Listing 2. Implementación del Cruce Espacial por AGEB

IV-C. Análisis de Hotspots

El análisis espacial reveló concentraciones críticas en alcaldías como Cuauhtémoc e Iztapalapa. Mediante el uso del "Índice Jerárquico", se distinguió entre incidentes aislados y patrones de violencia organizada que coinciden con zonas de alta densidad comercial.

V. CONCLUSIONES

La implementación de este pipeline demuestra que es posible transformar reportes no estructurados en activos estratégicos. La transición a un análisis microespacial permite identificar que la violencia criminal se concentra en nodos específicos de actividad urbana. El uso de Llama 3.2 mediante Ollama valida que la IA local es una herramienta escalable y privada para la seguridad pública moderna.

DISPONIBILIDAD DE CÓDIGO Y DATOS

El repositorio completo con los scripts de scraping, procesamiento de datos y la implementación de los dashboards de Streamlit se encuentra alojado en GitHub: <https://github.com/Isaac2234/eventus-cdmx>.

REFERENCIAS

- [1] J. Osorio and A. Beltrán, "Enhancing the Detection of Criminal Organizations in Mexico using ML and NLP," *IEEE ICDM*, 2020.
- [2] INEGI, "Marco Geoestadístico Nacional: Ciudad de México," 2020.
- [3] R. Smith, "An Overview of the Tesseract OCR Engine," *ICDAR*, 2007.
- [4] Meta AI, "Llama 3.2: Open Source Language Models," 2024.
- [5] Streamlit Inc., "Streamlit: The fastest way to build and share data apps," 2023.